

Министерство науки и высшего образования Российской Федерации
ФГАОУ ВО «УрФУ имени первого Президента России Б.Н. Ельцина»
Кафедра «Вычислительной математики и компьютерных наук»

Оценка работы _____
Шека Андрей Сергеевич

Применение искусственных нейронных сетей для анализа фазовых переходов
и механических свойств никелевых суперсплавов

ОТЧЕТ
Учебная практика

Руководитель практики от предприятия (организации) - Шека А. С.
ФИО руководителя Подпись

Студент Эсаулов Н.В.
ФИО студента

Специальность (направление подготовки) 02.04.01 Математика и компьютерные
науки

Группа МЕНМ-150201

Екатеринбург 2026

РЕФЕРАТ

Настоящая работа посвящена воспроизведению и анализу методов нейросетевого моделирования свойств никелевых жаропрочных сплавов. Рассмотрены две задачи: прогнозирование температуры сольвуса γ' -фазы по химическому составу сплава и моделирование зависимости прочности никелевых суперсплавов от параметра Ларсона–Миллера.

В первой части работы исследуется подход к прогнозированию температуры сольвуса с использованием искусственной нейронной сети с дифференциальным слоем. Особое внимание уделено подготовке входных данных: учету априорной информации о физической роли элементов в структуре жаропрочных сплавов. Такой подход позволяет представить состав сплава в более физически обоснованной форме и повысить интерпретируемость модели.

Во второй части рассматривается модель прогнозирования жаропрочности никелевых суперсплавов на основе байесовской регуляризованной искусственной нейронной сети BRANN. В качестве входных признаков используются химический состав и нормированный параметр Ларсона–Миллера, объединяющий температуру и время испытания. Для повышения устойчивости обучения прочность предварительно преобразуется в логарифмическую форму.

В работе описаны теоретические основы, подготовка данных, структура применяемых нейронных сетей, особенности реализации вычислительных экспериментов и основные результаты моделирования. Показано, что использование методов машинного обучения позволяет учитывать сложные нелинейные зависимости между химическим составом, температурно-временными условиями и свойствами никелевых жаропрочных сплавов.

Ключевые слова: никелевые жаропрочные сплавы, суперсплавы, температура сольвуса, γ' -фаза, искусственная нейронная сеть, дифференциальный слой, BRANN, байесовская регуляризация, параметр Ларсона–Миллера, жаропрочность.

СОДЕРЖАНИЕ

РЕФЕРАТ	2
Словарь терминов	5
ВВЕДЕНИЕ	9
1 Моделирование температуры сольвуса никелевых жаропрочных сплавов с использованием нейронной сети	11
1.1 Теоретические основы	11
1.1.1 Никелевые жаропрочные сплавы и температура сольвуса	11
1.1.2 Влияние легирующих элементов	11
1.2 Описание модели	12
1.2.1 Нейронная сеть	12
1.2.2 Учет априорной физической информации	12
1.2.3 Дифференцирующий слой	13
1.3 Реализация модели	14
1.3.1 Общая схема вычислительного эксперимента	14
1.3.2 Метрики качества	14
1.4 Результаты моделирования	15
1.4.1 Точечные результаты на тестовой выборке	15
1.4.2 Оценка качества модели по кросс-валидации	16
1.4.3 Неопределённость метрик по методу бутстрэпа	16
1.5 Выводы по главе	17
2 Прогнозирование жаропрочности никелевых суперсплавов с использованием BRANN и параметра Ларсона–Миллера	18
2.1 Теоретические основы	18
2.1.1 Жаропрочность никелевых суперсплавов	18
2.1.2 Параметр Ларсона–Миллера	18
2.2 Исходные данные	19
2.2.1 Структура базы данных	19
2.2.2 Преобразование химического состава и нормализация относительно никеля	19
2.2.3 Целевая переменная	21
2.3 Описание модели BRANN	21
2.3.1 Байесовская регуляризованная нейронная сеть	21
2.3.2 Архитектура нейронной сети	22
2.4 Реализация вычислительного эксперимента	22

2.4.1	Процедура обучения	22
2.4.2	Критерий ошибки	23
2.5	Результаты моделирования	23
2.5.1	Оценка точности на тестовой выборке	23
2.5.2	Сравнение распределений предсказанных и реальных значений	24
2.5.3	Согласованность предсказаний с экспериментальными данными	24
2.6	Выводы по главе	25
	ЗАКЛЮЧЕНИЕ	26
	БИБЛИОГРАФИЧЕСКИЙ СПИСОК	27

Словарь терминов

Никелевые жаропрочные сплавы - сложнолегированные металлические материалы на основе никеля, предназначенные для работы при высоких температурах, длительных нагрузках и в агрессивных средах. Характеризуются высокой жаропрочностью, коррозионной стойкостью и структурной стабильностью.

Суперсплавы - класс высоколегированных сплавов, сохраняющих механические свойства при температурах, близких к температуре плавления. В данной работе под суперсплавами преимущественно понимаются никелевые жаропрочные сплавы.

γ -матрица - основная фаза никелевых жаропрочных сплавов, представляющая собой твердый раствор на основе никеля с гранецентрированной кубической решеткой. В γ -матрице распределены упрочняющие фазы.

γ' -фаза - упрочняющая интерметаллидная фаза, она является одним из основных факторов высокой жаропрочности никелевых суперсплавов.

γ'' -фаза - упрочняющая метастабильная интерметаллидная фаза, характерная для некоторых никелевых сплавов, содержащих ниобий. Вносит вклад в повышение прочности, особенно при промежуточных температурах.

Температура сольвуса - температура, выше которой определенная фаза полностью растворяется в матрице сплава. В данной работе особое значение имеет температура сольвуса γ' -фазы, обозначаемая как T_{solvus} .

T_{solvus} - обозначение температуры сольвуса. Используется как целевая переменная при моделировании фазовой стабильности никелевых суперсплавов.

Легирование - введение в сплав дополнительных химических элементов с целью изменения его структуры и свойств. В никелевых суперсплавах легирование используется для повышения прочности, жаростойкости, коррозионной стойкости и фазовой стабильности.

Параметр Ларсона–Миллера - температурно-временной параметр, объединяющий температуру и время выдержки или разрушения:

$$P_{LM} = T(C + \log_{10} \tau).$$

Используется для описания длительной прочности и деградации материала при высоких температурах.

P_{LM}^* нормированная форма параметра Ларсона–Миллера:

$$P_{LM}^* = T(20 + \log_{10} \tau) \cdot 10^{-5}.$$

Нормировка используется для согласования масштаба данного параметра с концентрациями элементов во входном векторе нейронной сети.

Предел прочности - максимальное механическое напряжение, которое материал выдерживает до разрушения. Обозначается как σ .

σ - обозначение прочности или предела прочности сплава. В одной из моделей является целевой переменной, предсказываемой нейронной сетью.

Многослойный персептрон - тип нейронной сети прямого распространения, состоящий из входного слоя, одного или нескольких скрытых слоев и выходного слоя.

Скрытый слой - внутренний слой нейронной сети, в котором выполняется нелинейное преобразование входных данных.

Выходной слой - последний слой нейронной сети, формирующий итоговое предсказание модели.

Функция активации - нелинейная функция, применяемая к выходу нейрона. Позволяет нейронной сети моделировать нелинейные зависимости.

Обучение нейронной сети - процесс подбора весов и смещений сети с целью минимизации ошибки между предсказанными и экспериментальными значениями.

Обратное распространение ошибки - алгоритм вычисления градиентов ошибки по параметрам нейронной сети, используемый при ее обучении.

Переобучение - ситуация, при которой модель слишком хорошо запоминает обучающую выборку, но плохо предсказывает новые данные.

Регуляризация - метод ограничения сложности модели для уменьшения переобучения и повышения обобщающей способности.

BRANN - Bayesian Regularized Artificial Neural Network — искусственная нейронная сеть с байесовской регуляризацией. Используется для повышения устойчивости модели к переобучению.

Бутстреп - метод многократного случайного формирования обучающих и проверочных выборок из исходных данных. Используется для повышения надежности оценки модели.

Обучающая выборка - часть данных, используемая для настройки параметров модели.

Валидационная выборка - часть данных, используемая для контроля качества модели во время обучения и предотвращения переобучения.

Тестовая выборка - независимая часть данных, используемая для окончательной оценки качества обученной модели.

Априорная информация - заранее известные сведения о физической природе объекта моделирования. В данной работе это информация о роли легирующих элементов в структуре и свойствах суперсплавов.

Матрица связей - матрица, описывающая принадлежность легирующих элементов к различным группам влияния. Используется для внедрения физической информации в архитектуру нейронной сети.

Дифференциальный слой - слой нейронной сети, передающий информацию о чувствительности выходного параметра к изменению входных признаков.

MSE - Mean Squared Error — среднеквадратичная ошибка:

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2.$$

RMSE - Root Mean Squared Error — корень из среднеквадратичной ошибки. В отчете также используется относительная форма RMSE для оценки ошибки прогноза прочности.

RMAE - Relative Mean Absolute Error — относительная средняя абсолютная ошибка. Используется для оценки точности прогноза температуры сольвуса.

RRMSE - Relative Root Mean Squared Error — относительная среднеквадратичная ошибка. Используется для оценки качества модели при прогнозировании температуры сольвуса.

Химический состав - совокупность концентраций элементов, входящих в сплав. В моделях машинного обучения химический состав используется как входной вектор признаков.

Вектор признаков - набор численных характеристик объекта, передаваемый на вход модели. Для суперсплавов включает концентрации легирующих элементов и, при необходимости, параметр Ларсона–Миллера.

Целевая переменная - величина, которую необходимо предсказать с помощью модели. В данном отчете целевыми переменными являются температура сольвуса T_{solvus} и прочность σ .

ВВЕДЕНИЕ

Актуальность. В современной промышленности и материаловедении никелевые суперсплавы играют критически важную роль, особенно в авиастроении и энергетике, где требуются материалы, способные выдерживать экстремальные температуры и механические нагрузки. Традиционные методы подбора состава и прогнозирования свойств таких сплавов требуют проведения дорогостоящих и длительных физических экспериментов. В связи с этим, применение методов машинного обучения и искусственных нейронных сетей для ускорения процесса разработки новых материалов является высокоактуальной задачей.

Проблема. Несмотря на наличие больших массивов экспериментальных данных, классические эмпирические модели и физические уравнения часто не способны точно описать сложные нелинейные зависимости между химическим составом суперсплавов, параметрами термической обработки и их итоговыми физико-механическими свойствами. Это приводит к высокой погрешности прогнозов и необходимости многократного перебора вариантов при создании новых марок сплавов.

Целью работы является численное воспроизведение и анализ современных подходов к прогнозированию термических и механических свойств никелевых суперсплавов с использованием архитектур глубокого обучения и байесовских нейронных сетей.

Для достижения поставленной цели необходимо решить следующие задачи:

1. Изучить и воспроизвести модель глубокого обучения с дифференциальным слоем для прогнозирования температуры сольвуса никелевых суперсплавов.
2. Реализовать байесовскую регуляризованную нейронную сеть (BRANN) для прогнозирования предела прочности суперсплавов в зависимости от параметра Ларсона-Миллера.
3. Провести сравнительный анализ точности полученных нейросетевых моделей с оригинальными данными из научных статей.

Краткое содержание и результаты. В ходе выполнения работы был предобработан датасет, описывающий химический состав и свойства никелевых суперсплавов. Были реализованы две нейросетевые архитекту-

ры. В результате воспроизведения первой модели удалось достичь высокой точности предсказания температуры сольвуса. Во второй части работы с помощью BRANN удалось частично аппроксимирована зависимость предела прочности от параметра Ларсона-Миллера, но оптимальные параметры не были подобраны. Полученные результаты подтверждают эффективность применения методов машинного обучения в физике металлов.

1 Моделирование температуры сольвуса никелевых жаропрочных сплавов с использованием нейронной сети

1.1 Теоретические основы

1.1.1 Никелевые жаропрочные сплавы и температура сольвуса

Никелевые жаропрочные сплавы представляют собой сложнолегированные металлические материалы, предназначенные для работы при высоких температурах, механических нагрузках и агрессивных средах. Их высокая жаропрочность обусловлена многофазной структурой и наличием упрочняющих выделений, главным образом фаз γ' и γ'' . Основой большинства никелевых суперсплавов является γ -матрица на основе никеля. В ней распределены частицы упрочняющей γ' -фазы. Также в зависимости от состава могут присутствовать карбиды, бориды и другие интерметаллидные соединения.

Одним из важнейших параметров, характеризующих фазовую стабильность никелевого жаропрочного сплава, является температура сольвуса γ' -фазы T_{solvus} . Температура сольвуса соответствует температуре, выше которой упрочняющая фаза начинает растворяться в матрице. При превышении этой температуры структура сплава теряет устойчивость, что приводит к снижению прочностных характеристик.

Следовательно, прогнозирование температуры сольвуса по химическому составу является важной задачей при разработке новых жаропрочных сплавов и оптимизации уже существующих композиций.

1.1.2 Влияние легирующих элементов

Химический состав никелевых жаропрочных сплавов может включать большое количество элементов: Th, C, Cr, Co, Mo, W, Al, Ti, Nb, V, Fe, Y, Zr, Ta, Re, Ru, V, La, S, Si, Mn, P, Hf, Cu, Ge, Ga, Ni. Каждый из них выполняет определенную функцию.

Например, элементы Al, Ti, Ta и Nb участвуют в образовании упрочняющих интерметаллидных фаз. Cr и Al повышают стойкость к окислению и коррозии. Co, Mo, W, Re и Ta могут упрочнять твердый раствор. C, B, Zr и Hf влияют на границы зерен и образование карбидных фаз.

Влияние легирующих элементов является существенно нелинейным. Кроме того, один и тот же элемент может одновременно участвовать в нескольких физических механизмах. Поэтому построение простой аналитической зависимости между химическим составом и температурой сольвуса является затруднительным.

1.2 Описание модели

1.2.1 Нейронная сеть

Для прогнозирования температуры сольвуса используется искусственная нейронная сеть прямого распространения. В общем виде модель можно записать следующим образом:

$$\hat{T}_{\text{solvus}} = f_{\theta}(x_1, x_2, \dots, x_m), \quad (1.1)$$

где $\hat{T}_{\text{solvus}}$ — предсказанное значение температуры сольвуса, x_i — процентное содержание легирующего элемента, θ — обучаемые параметры модели.

Нейронная сеть выполняет роль нелинейного аппроксиматора, который устанавливает зависимость между химическим составом и температурой сольвуса. Преимущество такого подхода заключается в способности учитывать сложные нелинейные взаимодействия между элементами, которые трудно описать классическими аналитическими выражениями.

1.2.2 Учет априорной физической информации

Особенностью рассматриваемой модели является включение в архитектуру сети априорной информации о роли легирующих элементов. Элементы группируются по их влиянию на свойства сплава: твердорастворное упрочнение, образование карбидов, формирование γ' -фазы, повышение стойкости к окислению, стабилизация границ зерен и т.д.

Эта информация может быть представлена в виде матрицы связей:

$$R = [r_{gi}], \quad (1.2)$$

где r_{gi} показывает, относится ли элемент i к группе влияния g . Если элемент входит в соответствующую группу, то $r_{gi} = 1$, иначе $r_{gi} = 0$.

Для каждой группы можно сформировать обобщенный сигнал:

$$s_g = \sum_{i=1}^m r_{gi} x_i, \quad (1.3)$$

где s_g — суммарный вклад элементов, относящихся к g -й группе.

Таким образом, нейронная сеть получает не только численные концентрации элементов, но и информацию об их физической роли в структуре сплава.

1.2.3 Дифференцирующий слой

Дифференцирующий слой формирует два нелинейных преобразования входного сигнала группы:

$$\mathbf{p}_g = \tanh(W_g^+ \mathbf{x}_g + \mathbf{b}_g^+),$$

$$\mathbf{n}_g = \tanh(W_g^- \mathbf{x}_g + \mathbf{b}_g^-),$$

где W_g^+ и W_g^- — обучаемые матрицы весов, а $\mathbf{b}_g^+$ и $\mathbf{b}_g^-$ — векторы смещений. В данной модели смещениям установлены значения

$$\mathbf{b}_g^+ = 0.5, \quad \mathbf{b}_g^- = -0.5.$$

Дифференцированный сигнал определяется как разность двух нелинейных преобразований:

$$\mathbf{d}_g = \mathbf{p}_g - \mathbf{n}_g.$$

Такое представление позволяет сети учитывать не только суммарное содержание элементов в группе, но и различия в характере их влияния на целевое свойство.

Выход g -й ветви дифференцирующего слоя записывается в виде

$$\mathbf{h}_g = [s_g, \mathbf{p}_g, \mathbf{n}_g, \mathbf{d}_g].$$

После обработки всех групп выходные векторы объединяются:

$$\mathbf{h} = [\mathbf{h}_1, \mathbf{h}_2, \dots, \mathbf{h}_G],$$

где G — число групп легирующих элементов.

Итоговый вход последующей полносвязной части сети формируется путем объединения исходного вектора состава и группового дифференцированного сигнала:

$$\mathbf{z} = [\mathbf{x}, \mathbf{h}].$$

Затем вектор $\mathbf{z}$ поступает на полносвязную нейронную сеть:

$$\hat{y} = f_{\theta}(\mathbf{z}),$$

где $\hat{y}$ — прогнозируемое значение температуры сольвуса, а f_{θ} — обучаемая нелинейная функция, реализуемая скрытыми слоями нейронной сети.

Таким образом, дифференцирующий слой выполняет две функции. Во-первых, он внедряет в архитектуру сети априорную информацию о физической роли легирующих элементов. Во-вторых, он формирует дополнительные нелинейные признаки, описывающие групповой и дифференцированный вклад элементов в прогнозируемое свойство.

1.3 Реализация модели

1.3.1 Общая схема вычислительного эксперимента

Реализация модели включает следующие этапы:

1. формирование матрицы связей, описывающей физическую роль легирующих элементов;
2. построение глубокой нейронной сети с дифференциальным слоем;
3. обучение модели на подготовленных данных;
4. оценка точности прогноза по выбранным метрикам.

1.3.2 Метрики качества

Для оценки качества прогноза могут использоваться относительная средняя абсолютная ошибка и относительная среднеквадратичная ошибка.

Относительная средняя абсолютная ошибка определяется выражением:

$$RMAE = \frac{1}{n} \sum_{i=1}^n \left| \frac{T_i - \hat{T}_i}{T_i} \right| \cdot 100\%, \quad (1.4)$$

где T_i — экспериментальное значение температуры сольвуса, $\hat{T}_i$ — предсказанное значение, n — количество объектов в выборке.

Относительная среднеквадратичная ошибка определяется как:

$$RRMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n \left(\frac{T_i - \hat{T}_i}{T_i} \right)^2}. \quad (1.5)$$

1.4 Результаты моделирования

В результате применения нейронной сети была получена модель, способная прогнозировать температуру сольвуса никелевых жаропрочных сплавов по их химическому составу. Использование априорной информации о роли элементов позволило повысить физическую обоснованность входных данных.

По данным воспроизводимой статьи, модель показала достаточно высокую точность: относительная средняя абсолютная ошибка составила около $RMAE = 5.89\%$, а относительная среднеквадратичная ошибка — около $RRMSE = 0.09$.

1.4.1 Точечные результаты на тестовой выборке

На тестовой выборке были получены предсказания $\hat{y}$ и вычислены ошибки. Для иллюстрации качества работы модели в таблице приведены 5 случаев с наибольшими значениями ошибки на тесте.

y_{true}	y_{pred}	$ e $	$rel_error(\%)$
773.15	1191.20	418.05	54.07
973.15	1285.83	312.68	32.13
1023.15	1224.65	201.50	19.69
1373.15	1154.06	219.08	15.95
1143.15	967.36	175.78	15.37

Таблица 1 — Пять худших предсказаний на тестовой выборке

1.4.2 Оценка качества модели по кросс-валидации

Для проверки устойчивости обучения использовалась кросс-валидация: модель переобучалась на каждом фолде и вычислялись метрики. Итоговые значения представлены медианой и дисперсией по фолдам.

Метрика	Медиана	Дисперсия
RRMAE (%)	4.36	0.79
RRMSE	0.08	0.0001

Таблица 2 — Сводные результаты кросс-валидации

1.4.3 Неопределённость метрик по методу бутстрэпа

Для дополнительно оценки устойчивости метрик вычислялись распределения RRMAE и RRMSE с помощью бутстрэпа. Квантили 2.5% и 97.5% соответствуют приближённому доверительному интервалу, а вертикальная линия (медиана) показывает центральную тенденцию. Рисунки 1–2 иллюстрируют полученные распределения.




Рисунок 1 — Распределение RRMAE (%) по бутстрэп-выборкам

Итак, таблица 1 показывает поведение модели на тесте в наиболее проблемных случаях, кросс-валидация (табл. 2) оценивает устойчивость качества при повторном обучении на различных фолдах, а бутстрэп (рис. 1–2) предоставляет распределения метрик и их доверительные интервалы.




Рисунок 2 — Распределение RRMSE по бутстрэп-выборкам

1.5 Выводы по главе

Полученные результаты показывают, что нейронная сеть с дифференциальным слоем может быть использована для прогнозирования температуры сольвуса сложнолегированных никелевых суперсплавов. Такой подход особенно эффективен в условиях, когда аналитическое описание зависимости между составом и свойствами затруднено из-за высокой нелинейности и многокомпонентности системы.

Основными особенностями модели являются:

- учет физической роли легирующих элементов;
- применение дифференциального слоя для анализа чувствительности модели.

Эта глава, была попыткой воспроизвести статью [1]

2 Прогнозирование жаропрочности никелевых суперсплавов с использованием BRANN и параметра Ларсона–Миллера

2.1 Теоретические основы

2.1.1 Жаропрочность никелевых суперсплавов

Жаропрочность является одной из ключевых характеристик никелевых суперсплавов. Она определяет способность материала сохранять прочность при длительном воздействии высокой температуры и механической нагрузки.

В условиях высокотемпературной эксплуатации структура суперсплава постепенно деградирует. Происходит укрупнение упрочняющих фаз, изменение морфологии выделений, перераспределение легирующих элементов и накопление повреждений. В результате предел прочности σ снижается.

Для описания изменения прочности при различных температурах и временах выдержки удобно использовать обобщенные температурно-временные параметры. Одним из наиболее распространенных является параметр Ларсона–Миллера.

2.1.2 Параметр Ларсона–Миллера

Параметр Ларсона–Миллера объединяет температуру и время выдержки в одну величину:

$$P_{LM} = T (20 + \log_{10} \tau), \quad (2.1)$$

где T — температура испытания, τ — время выдержки или длительность испытания.

В рассматриваемой работе используется нормированная форма параметра:

$$P_{LM}^* = T (20 + \log_{10} \tau) \cdot 10^{-5}. \quad (2.2)$$

Нормировка необходима для того, чтобы значения параметра Ларсона–Миллера были сопоставимы по порядку величины с концентрациями

легирующих элементов, используемыми как входные признаки нейронной сети.

Параметр P_{LM}^* отражает степень температурно-временного воздействия на материал. При увеличении этого параметра прочность сплава, как правило, снижается вследствие термической деградации структуры.

2.2 Исходные данные

2.2.1 Структура базы данных

Для обучения модели использовалась база данных никелевых суперсплавов, содержащая сведения о химическом составе и результатах механических испытаний.

В качестве входных признаков использовались содержания легирующих элементов:

$$\mathbf{x} = (c_1, c_2, \dots, c_m, P_{LM}^*), \quad (2.3)$$

где c_i — концентрация i -го легирующего элемента, m — количество учитываемых элементов.

В базе данных учитывались следующие элементы:

$$\begin{aligned} &\text{Th, C, Cr, Co, Mo, W, Al, Ti, Nb, B, Fe, Y, Zr, Ta,} \\ &\text{Re, Ru, V, La, S, Si, Mn, P, Hf, Cu, Ge, Ga, Ni} \end{aligned} \quad (2.4)$$

Всего база содержала 1049 отдельную запись, каждая из которых соответствовала конкретному химическому составу и определенному условию испытания.

2.2.2 Преобразование химического состава и нормализация относительно никеля

Исходные данные о химическом составе никелевых суперсплавов в большинстве случаев задаются в массовых процентах. Однако для описания фазообразования и взаимодействия легирующих элементов более физически обоснованным является использование атомных соотношений, поскольку образование фаз определяется числом атомов, а не их массой.

Поэтому на первом этапе выполнялось преобразование массовых концентраций в атомные доли. Для каждого элемента вычислялась величина

$$q_i = \frac{w_i}{A_i}, \quad (2.5)$$

где w_i — массовое содержание i -го элемента, а A_i — его атомная масса. Затем атомная доля элемента определялась как

$$x_i = \frac{q_i}{\sum_{j=1}^m q_j} = \frac{w_i/A_i}{\sum_{j=1}^m w_j/A_j}, \quad (2.6)$$

где m — количество элементов, входящих в химический состав сплава.

Так как никель является основой рассматриваемых суперсплавов, на следующем этапе атомные доли легирующих элементов нормировались относительно атомной доли никеля:

$$z_i = \frac{x_i}{x_{\text{Ni}}}, \quad (2.7)$$

где z_i — относительное содержание i -го легирующего элемента по отношению к никелевой матрице, x_i — атомная доля данного элемента, а x_{Ni} — атомная доля никеля.

Таким образом, величина z_i показывает, сколько атомов легирующего элемента приходится на один атом никеля. Например, если $z_{\text{Cr}} = 0.12$, это означает, что на один атом никеля приходится приблизительно 0.12 атома хрома, или около 12 атомов хрома на 100 атомов никеля.

Итоговый входной вектор модели записывался в виде

$$\mathbf{x} = (z_1, z_2, \dots, z_m, P_{LM}^*), \quad (2.8)$$

где z_i — атомная доля легирующего элемента, нормированная относительно никеля, а P_{LM}^* — нормированный параметр Ларсона–Миллера.

Такое преобразование имеет несколько преимуществ. Во-первых, оно переводит химический состав из массовой формы в атомную, что лучше соответствует физической природе фазовых превращений. Во-вторых, никель исключается из набора независимых признаков, поскольку он является матричным элементом. В-третьих, нормировка относительно никеля приводит значения входных переменных к близкому численному диапазону, что облегчает обучение нейронной сети методом обратного распространения ошибки.

2.2.3 Целевая переменная

Целевой переменной являлась прочность σ при заданных условиях температурно-временного воздействия. Так как значения прочности могут изменяться в широком диапазоне, перед обучением применялось логарифмическое преобразование:

$$y = -\log_{10} \sigma. \quad (2.9)$$

Обратное преобразование выполнялось по формуле:

$$\sigma = 10^{-y}. \quad (2.10)$$

Такое преобразование позволяет уменьшить влияние больших значений прочности на процесс обучения, а также исключает появление отрицательных значений прочности после обратного преобразования.

2.3 Описание модели BRANN

2.3.1 Байесовская регуляризованная нейронная сеть

Для прогнозирования прочности использовалась байесовская регуляризованная искусственная нейронная сеть BRANN. Она является разновидностью многослойного персептрона, в котором обучение сопровождается регуляризацией весовых коэффициентов.

В общем виде прогноз модели записывается как:

$$\hat{y} = f_{\theta}(c_1, c_2, \dots, c_m, P_{LM}^*), \quad (2.11)$$

где $\hat{y}$ — предсказанное значение логарифмически преобразованной прочности, θ — параметры нейронной сети.

Байесовская регуляризация используется для уменьшения риска переобучения. При обучении минимизируется функционал:

$$F = \beta E_D + \alpha E_W, \quad (2.12)$$

где E_D — ошибка на обучающих данных, E_W — сумма квадратов весов сети, α и β — параметры регуляризации.

Ошибка на данных определяется как:

$$E_D = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2. \quad (2.13)$$

Регуляризационный член имеет вид:

$$E_W = \sum_j w_j^2, \quad (2.14)$$

где w_j — весовые коэффициенты нейронной сети.

2.3.2 Архитектура нейронной сети

В рассматриваемой работе использовалась сеть с одним скрытым слоем. Входной слой содержал признаки химического состава и параметр Ларсона–Миллера. Скрытый слой включал 10 нейронов. Выходной слой состоял из одного нейрона, выдающего значение $\hat{y}$.

Схематично модель можно представить следующим образом:

$$(c_1, c_2, \dots, c_m, P_{LM}^*) \rightarrow \text{Hidden}(10) \rightarrow \hat{y}. \quad (2.15)$$

После получения прогноза $\hat{y}$ выполнялось обратное преобразование:

$$\hat{\sigma} = 10^{-\hat{y}}. \quad (2.16)$$

2.4 Реализация вычислительного эксперимента

2.4.1 Процедура обучения

обучающая часть выборки составляла 90% процентов, а тестовая 10%. Так как для BRANN не нужна валидация результата.

Общая процедура обучения включала следующие этапы:

1. формирование входного массива из концентраций легирующих элементов и параметра P_{LM}^* ;
2. логарифмическое преобразование целевой переменной σ ;
3. случайное разделение данных на обучающую и валидационную выборки;
4. обучение BRANN-модели;
5. обратное преобразование результата к значениям прочности.

2.4.2 Критерий ошибки

Во время обучения использовалась среднеквадратичная ошибка:

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_{predicted,i} - y_{real,i})^2, \quad (2.17)$$

где $y_{predicted,i}$ — прогноз нейронной сети, $y_{real,i}$ — реальное значение после логарифмического преобразования.

Для оценки точности прогноза прочности использовалась относительная среднеквадратичная ошибка:

$$RMSE = \sqrt{\frac{1}{k} \sum_{j=1}^k \left(\frac{\sigma_{predicted,j} - \sigma_{real,j}}{\sigma_{real,j}} \right)^2}. \quad (2.18)$$

Здесь $\sigma_{predicted,j}$ — предсказанное значение прочности, $\sigma_{real,j}$ — экспериментальное значение прочности, k — количество объектов в выборке.

2.5 Результаты моделирования

Я думаю модель можно было сделать еще лучше, подобрать оптимальные параметры, уменьшить переобучение, добавить ансамбль из нескольких BRANN, как например в исходной статье,

По итогам обучения и проверки модели на тестовой выборке были получены следующие показатели качества прогноза прочности σ (в МПа).

2.5.1 Оценка точности на тестовой выборке

Значения метрик качества составили:

- RMSE (абсолютная) — 370.80 МПа;
- RMSE (относительная) — 2.1359;
- минимальное предсказанное значение прочности — 49.33 МПа;
- максимальное предсказанное значение прочности — 1654.34 МПа;
- минимальное реальное (экспериментальное) значение прочности — 57.68 МПа;
- максимальное реальное значение прочности — 1337.58 МПа.

Приведенные результаты показывают, что предсказания модели воспроизводят общий диапазон прочности и способны давать оценки как для низко-, так и для высокопрочных состояний сплава.

2.5.2 Сравнение распределений предсказанных и реальных значений

Сопоставление распределений σ на тестовой выборке показано на рисунке 3. Распределение предсказанных значений (pred) повторяет форму распределения истинных значений (test), при этом наблюдаются различия в области наиболее плотного скопления данных. Это может быть связано с ограниченным числом объектов в поддиапазонах прочности и с неоднородностью зависимости σ от температурно-временных условий и состава.




Рисунок 3 — Распределение предсказанных (pred) и истинных (test) значений прочности σ на тестовой выборке.

2.5.3 Согласованность предсказаний с экспериментальными данными

На рисунке 4 представлена диаграмма соответствия: по оси абсцисс отложены истинные значения σ , по оси ординат — предсказанные $\hat{\sigma}$. Штриховая линия соответствует идеальному совпадению $\hat{\sigma} = \sigma$.

В целом точки распределены вокруг линии идеального соответствия, что свидетельствует о приемлемом качестве прогноза. Отклонения от диагонали отражают ошибки модели, которые особенно заметны для отдельных интервалов прочности, где характер зависимости может быть более сложным.




Рисунок 4 — Диаграмма “предсказанное vs истинное” для прочности σ на тестовой выборке. Штриховая линия соответствует равенству $\hat{\sigma} = \sigma$.

2.6 Выводы по главе

В данной главе рассмотрена модель прогнозирования жаропрочности никелевых суперсплавов с использованием байесовской регуляризованной искусственной нейронной сети и параметра Ларсона–Миллера.

Основные особенности подхода заключаются в следующем:

- химический состав и параметр Ларсона–Миллера используются как входные признаки;
- прочность преобразуется в логарифмическую форму для повышения устойчивости обучения;
- используется BRANN-модель, устойчивая к переобучению;

Эта глава, была попыткой воспроизвести статью [2]

ЗАКЛЮЧЕНИЕ

Таким образом, в процессе выполнения работы были решены следующие задачи:

- Была изучена и реализована модель обучения с дифференциальным слоем. В ходе численного эксперимента подтверждено, что данная архитектура позволяет эффективно прогнозировать температуру сольвуса с высокой точностью, что решает первую поставленную задачу.

- Для прогнозирования предела прочности была обучена байесовская регуляризованная нейронная сеть (BRANN). Вторая задача решена в не полном объеме.

- Проведенный сравнительный анализ показал, что воспроизведенные модели демонстрируют результаты, сопоставимые с оригинальными данными из научных статей, что подтверждает их адекватность и применимость в задачах материаловедения.

В пути дальнейшей работы входит донастройка параметров сети и/или проба другой архитектуры нейронно сетию

Таким образом, поставленная цель работы достигнута. Результаты исследования демонстрируют высокий потенциал методов искусственного интеллекта для ускорения разработки и оптимизации состава жаропрочных никелевых суперсплавов.

БИБЛИОГРАФИЧЕСКИЙ СПИСОК

1. *Dmitry Tarasov Andrey Tyagunov, O. M.* Simulation of the nickel superalloys solvus temperature by the deep learning artificial neural network with differential layer / O. M. Dmitry Tarasov Andrey Tyagunov. — 2022.
2. *Dmitry Tarasov Andrey Tyagunov, O. M.* BRANN forecast of superalloy tensile strength versus Larson–Miller parameter relation and its approximation by a sigmoidal function / O. M. Dmitry Tarasov Andrey Tyagunov. — 2022.